




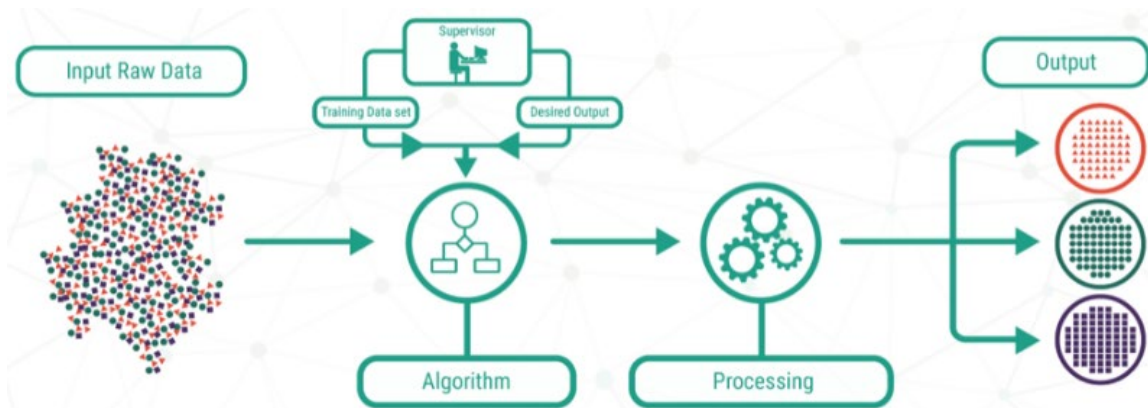
# Linear Factor Models

Deep Learning Study: Chap 13

신성호  
2023.

# Overview of Part III

- Part I,II : 지도 학습의 문제를 푸는 방법들





- 벡터 사상

- 한 벡터로부터 다른 벡터로의 사상에 대한 건본이 충분히 주어졌을 때 학습

# Overview of Part III

- 지도학습으로 해결할 수 없는 문제
  - 새 건본 생성, 발생 가능성 추정, 결측값 처리, 라벨링이 되지 않은 건본





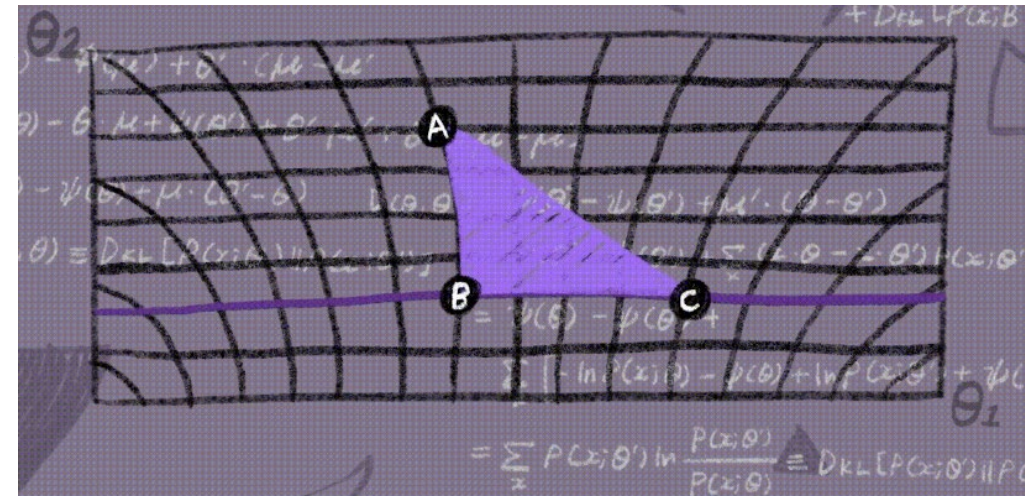
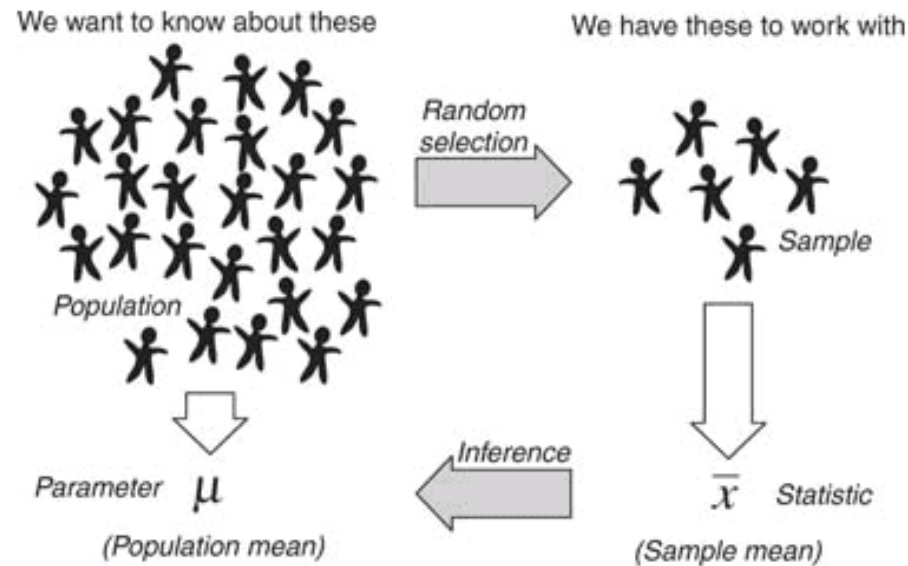


# Overview of Part III

- 계산적 어려움(Computational challenge)
  - 고차원 분포에서 학습 또는 학습된 모델을 활용하는 여러 알고리즘에 **처리 불가능한 계산** 관여



- 처리 불가능한 추론

- 처리 불가능한 정규화 상수



# Overview of Part III

- 처리 불가능한 정규화 상수 (분배 함수 – Partition function)
  - 분배함수의 계산 자체가 처리 불가능



# Overview of Part III

- 처리 불가능 계산 문제를 해결하는 방법?
  - 참값이 아닌 근삿값을 사용
  - 생성 모형화 (제 20장)
- ‘연구자’ 에게 해당하는 독자에게 가장 중요한 파트

# Chap XIII – Linear Factor Model

- 입력 확률 모형의 구축은 심층 학습의 최신 연구 주제의 핵심
  - 잠재변수  $\mathbf{h}$ :  $p_{\text{모형}}(\mathbf{x}) = \mathbb{E}_{\mathbf{h}} p_{\text{모형}}(\mathbf{x}|\mathbf{h})$  를 만족
- 선형 인자 모형 ( Linear Factor Model)
  - 혼합 모형의 구성요소
  - 더 큰 심층 확률 모형의 구성요소
  - 생성 모형 - generative model (고급의 심층 모형을 더욱 확장)




# Chap XIII – Linear Factor Model

- 확률적 선형 복호기 (stochastic linear decoder) 함수 활용
  - 잠재변수  $\mathbf{h}$  의 선형 변환에 잡음을 더함
  - 단순한 결합분포를 가진 설명 인자(explanatory factor)들을 발견

$$\mathbf{h} \sim p(\mathbf{h}).$$

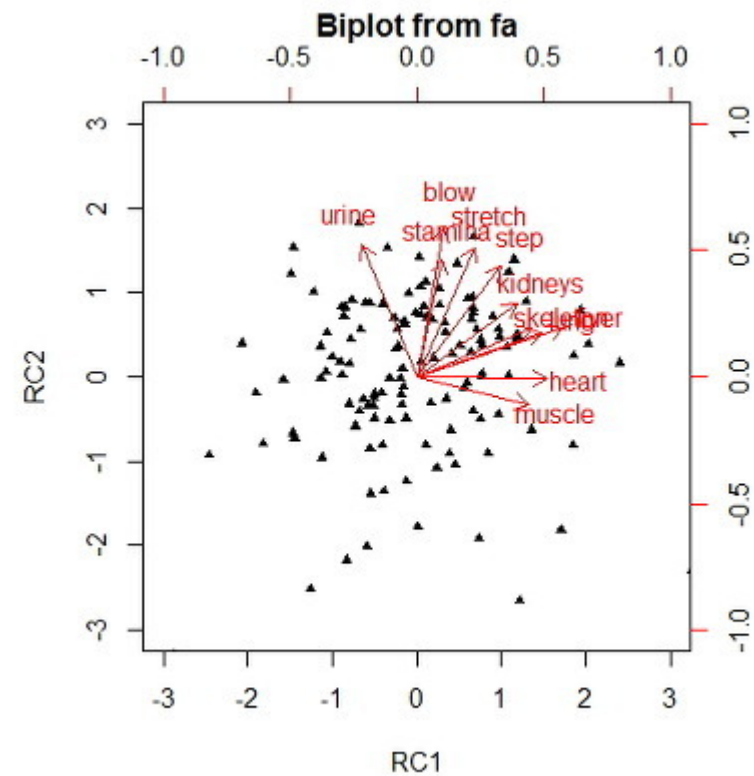

$$p(\mathbf{h}) = \prod_i p(h_i)$$

$$\mathbf{x} = \mathbf{W}\mathbf{h} + \mathbf{b} + \text{잡음}.$$



# 13.1 확률적 PCA & 인자분석



- 인자분석 (Factor Analysis)
  - 서로 관련 있는 변수에서 어떤 잠재 변수  $h$ 가 분산을 설명하는가?



# 13.1 확률적 PCA & 인자분석

## ● 주성분분석 (PCA)

- 원 데이터의 분포를 최대한 보존하면서 고차원 공간의 데이터를 저차원 공간으로 변환



# 13.1 확률적 PCA & 인자분석

## ● 인자분석의 특징

- 잠재변수의 사전 분포는 단위 분산 가우스 분포

$$\mathbf{h} \sim \mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{I})$$

- 관측변수(observed variable)들이 조건부 독립

- 잡음을 대각 공분산 가우스 분포에서 얻음

$$\boldsymbol{\psi} = \text{diag}(\boldsymbol{\sigma}^2) \quad \boldsymbol{\sigma}^2 = [\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2]^\top$$

- 잠재변수들은 서로 다른 관측변수들 사이의 의존성을 포착

$$\mathbf{x} \sim \mathcal{N}(\mathbf{x}; \mathbf{b}, \underbrace{\mathbf{W}\mathbf{W}^\top}_{\text{공분산}} + \boldsymbol{\psi}).$$



## 13.1 확률적 PCA & 인자분석

- 주성분분석(PCA) : 조건부 분산들이 모두 같아짐

$$\mathbf{x} \sim \mathcal{N}(\mathbf{x}; \mathbf{b}, \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}).$$



$$\mathbf{x} = \mathbf{W}\mathbf{h} + \mathbf{b} + \sigma\mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$$

반복적인 EM 알고리즘을 이용해서 매개변수  $\mathbf{W}$ 와  $\sigma^2$ 을 추정할 수 있다.

- PCA가 정의하는 밀도 모형은  $\mathbf{W}$ 의 열들이 차지하는  $d$ 개의 차원들 주변에서 아주 날카로워짐

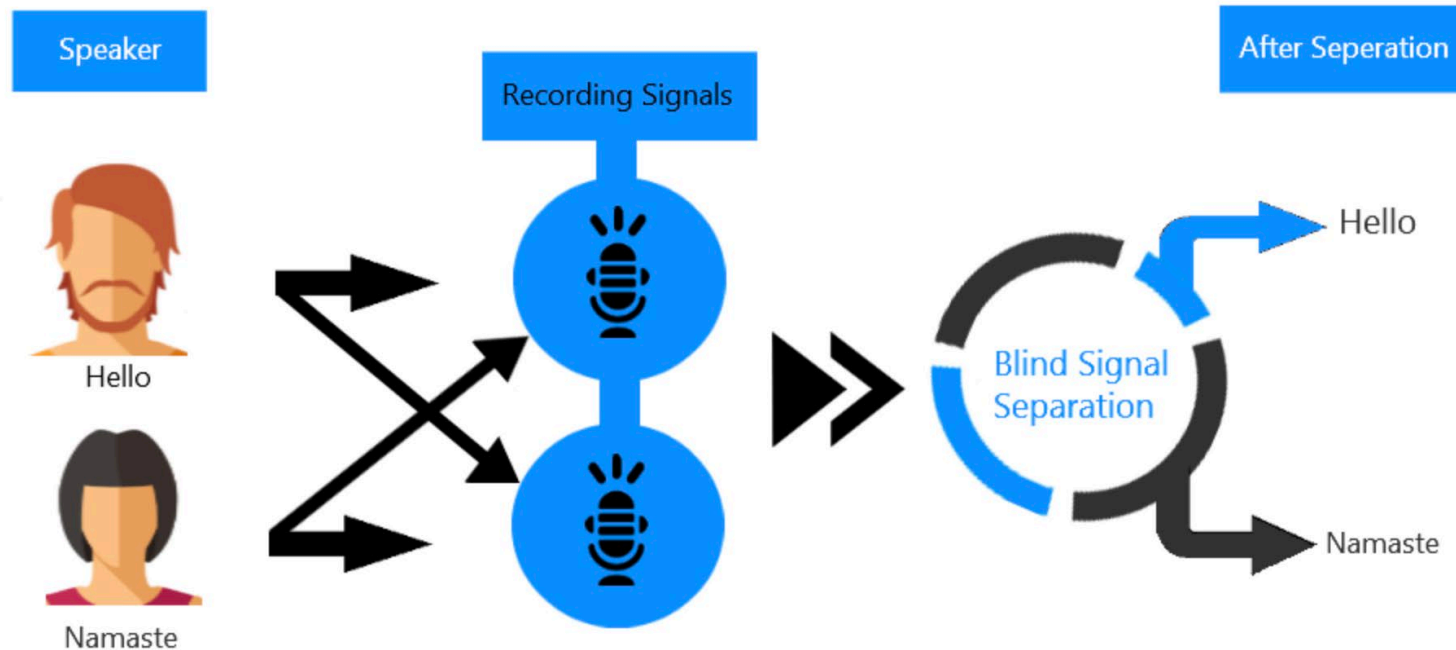
# 13.1 확률적 PCA & 인자분석

- 확률적 주성분분석(PCA) VS 인자분석(FA)
  - 변수간 중요성? 선형 독립?



## 13.2 독립성분분석(ICA)

- 관측된 신호를 여러 바탕 신호로 분리하여 관측 자료를 만들어 냄



## 13.2 독립성분분석

- 신호들은 서로 상관관계가 없으며 완전히 독립
  - 완전 매개변수적 생성 모형 훈련
  - 사전분포를 미리 사용자가 명시적으로 지정
  - 모형은 결정론적으로  $\mathbf{x} = \mathbf{W}\mathbf{h}$  를 생성



## 13.2 독립성분분석

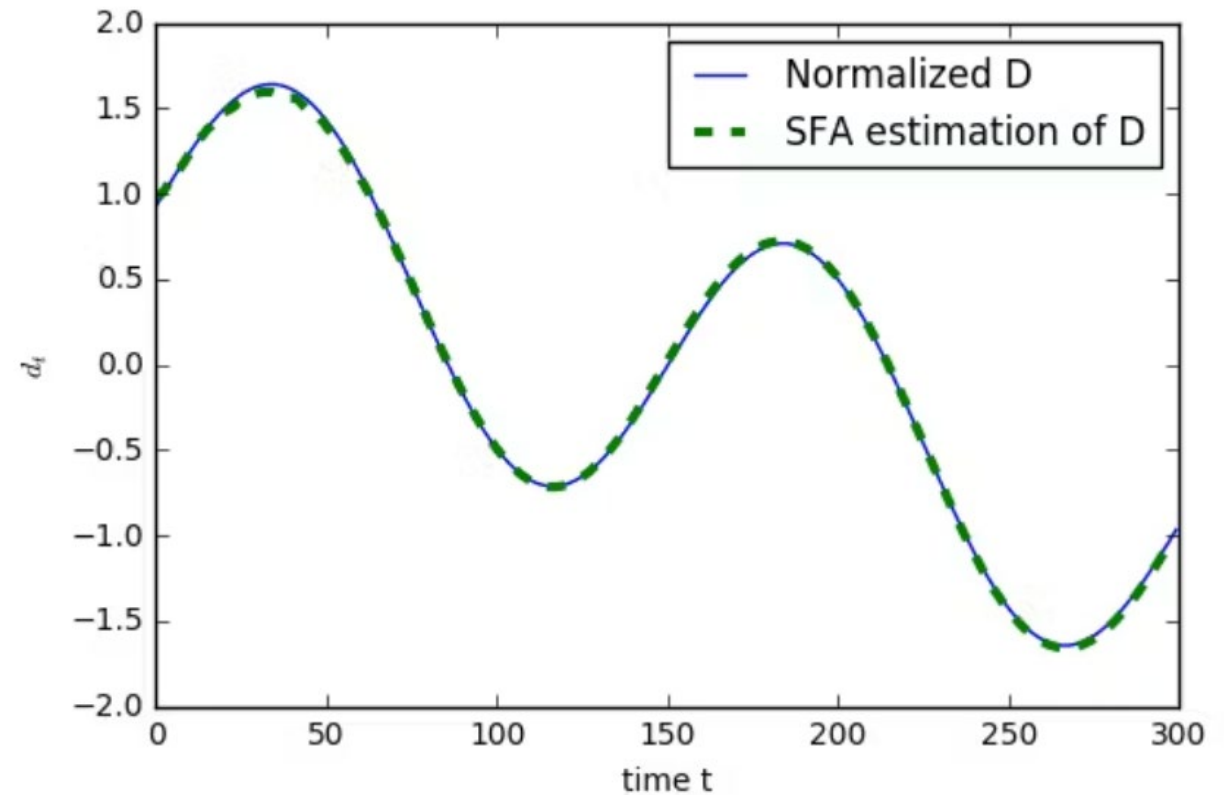

- 다양한 변형 존재
  - 최대 가능도(우도)를 사용하는 방법
  - 결정론적 복호기를 사용하는 대신 잡음을 추가하여 생성
  - 최대 가능도 방법 대신  $\mathbf{h} = \mathbf{W}^{-1}\mathbf{x}$  성분들이 서로 독립이도록 하는 방법
  - $\mathbf{W}$ 를 직교행렬로 제한
- $p(\mathbf{h})$ 가 반드시 비 가우스 분포
  - 표본 첨도가 높아짐 - 비 가우스 분포

## 13.2 독립성분분석

- 다양한 변형 존재
  - 최대 가능도(우도)를 사용하는 방법
  - 결정론적 복호기를 사용하는 대신 잡음을 추가하여 생성
  - 최대 가능도 방법 대신  $\mathbf{h} = \mathbf{W}^{-1}\mathbf{x}$  성분들이 서로 독립이도록 하는 방법
  - $\mathbf{W}$ 를 직교행렬로 제한
- $p(\mathbf{h})$ 가 반드시 비 가우스 분포
  - 표본 첨도가 높아짐 - 비 가우스 분포

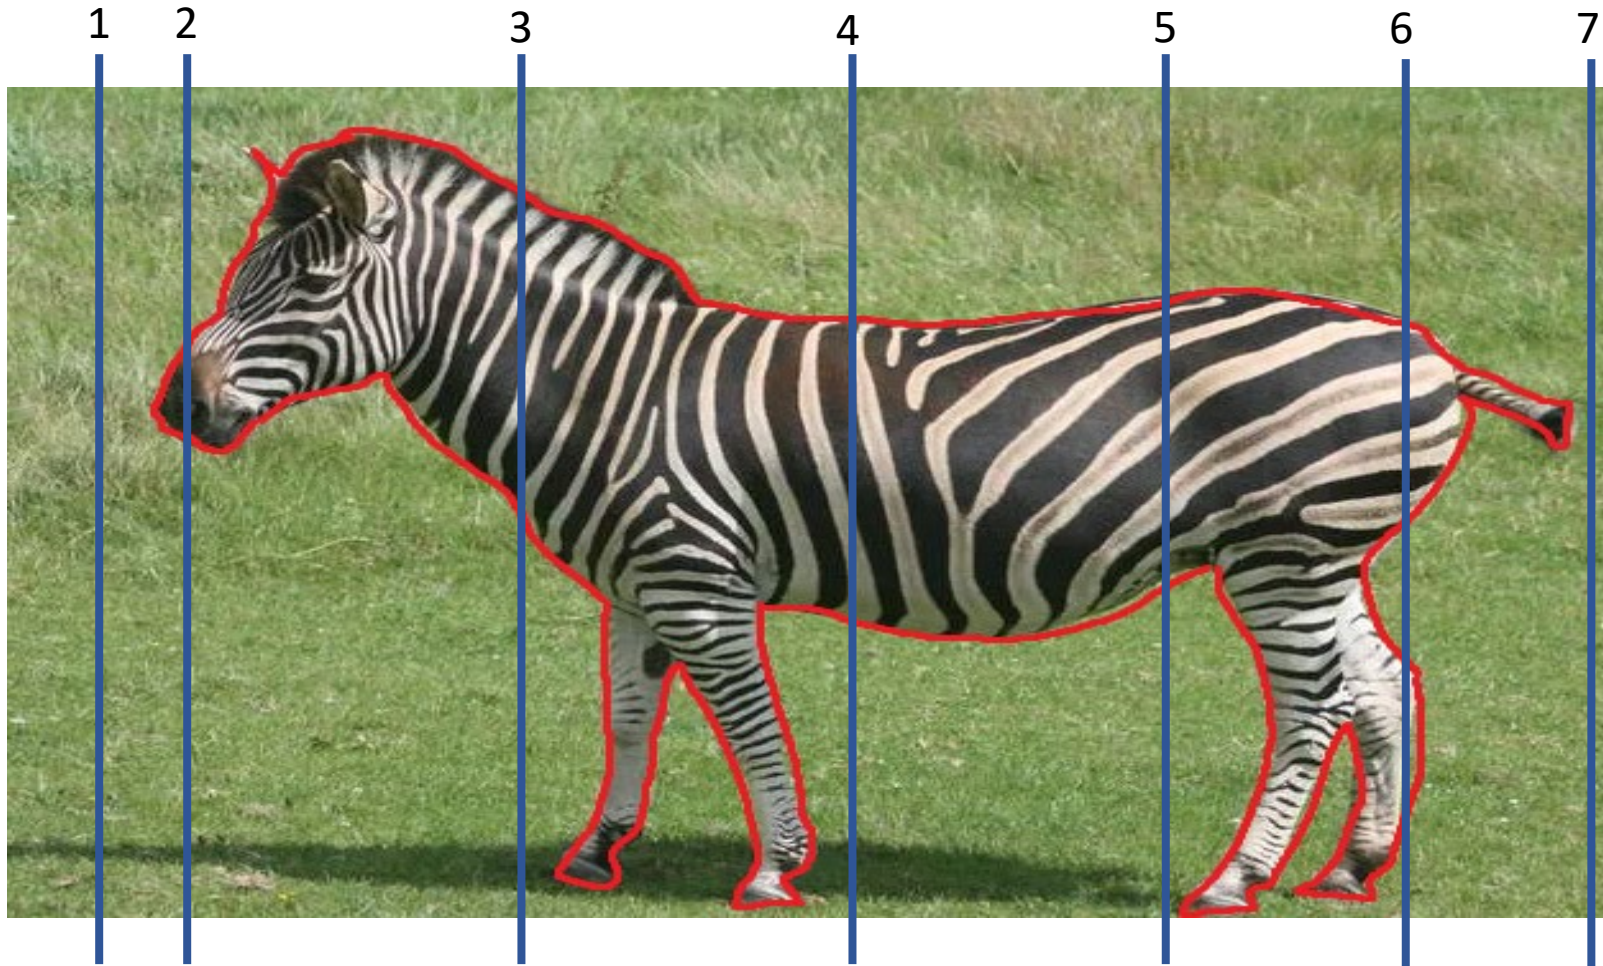
## 13.3 느린특징분석(SFA)

- 느림 원리에 기초
  - 시간 신호에 있는 정보를 이용해서 불변의 특징을 학습



## 13.3 느린특징분석(SFA)

- 장면의 중요한 특징들은 그 장면의 서술을 구성하는 측도보다 느리게 변함





## 13.3 느린특징분석(SFA)

- 비용 함수에 다음 항 추가:  $\lambda \sum_t L(f(\mathbf{x}^{(t+1)}), f(\mathbf{x}^{(t)}))$ .
  - $\lambda$  는 느림 정착화 항의 강도를 결정하는 초매개변수
  - $t$ 는 시간순 건본 순차열의 특정 건본을 지칭하는 시간 색인
  - $f$ 는 정착화할 특징 추출기
  - $L$ 은  $f(\mathbf{x}^{(t)})$  와  $f(\mathbf{x}^{(t+1)})$  의 거리를 측정하는 손실 함수

## 13.3 느린특징분석(SFA)

- 느린 특징 분석은 느린 원리의 여러 응용 중 특히 효율적임
- SFA 알고리즘은 선형 변환으로 정의됨

$$\min_{\theta} \mathbb{E}_t (f(\mathbf{x}^{(t+1)})_i - f(\mathbf{x}^{(t)})_i)^2.$$

$$\mathbb{E}_t f(\mathbf{x}^{(t)})_i = 0$$

$$\forall i < j, \mathbb{E}_t [f(\mathbf{x}^{(t)})_i f(\mathbf{x}^{(t)})_j] = 0.$$

$$\mathbb{E}_t [f(\mathbf{x}^{(t)})_i^2] = 1$$

## 13.4 희소 부호화

- 비지도 특징 학습과 특징 추출 매커니즘

- 하나의 선형 복호기에  $x$ 의 재구축을 위한 잡음 더함 - 등방 정밀도

$$p(\mathbf{x}|\mathbf{h}) = \mathcal{N}(\mathbf{x}; \mathbf{W}\mathbf{h} + \mathbf{b}, \frac{1}{\beta}\mathbf{I})$$

- $p(\mathbf{h})$ 는 봉우리가 날카로운 분포를 선택

- 인수분해된 라플라스 분포, 코시 분포, 인수분해된 스튜던트 분포

## 13.4 희소 부호화

- 희소 부호화를 최대 가능도로 훈련하는 것은 처리 불가능 문제에 해당
  - 자료의 부호화와 복호기의 훈련을 번갈아 수행

$$p(\mathbf{x}|\mathbf{h}) = \mathcal{N}(\mathbf{x}; \mathbf{W}\mathbf{h} + \mathbf{b}, \frac{1}{\beta}\mathbf{I})$$

- 가중치 행렬의 곱셈으로 이루어진 매개변수적 부호기 함수 이용하지 않음
  - 최적화 문제를 푸는 방법

$$\begin{aligned} & \operatorname{argmax}_{\mathbf{h}} p(\mathbf{h}|\mathbf{x}) \\ &= \operatorname{argmax}_{\mathbf{h}} \log p(\mathbf{h}|\mathbf{x}) \\ &= \operatorname{argmin}_{\mathbf{h}} \lambda \|\mathbf{h}\|_1 + \beta \|\mathbf{x} - \mathbf{W}\mathbf{h}\|_2^2. \end{aligned}$$



## 13.4 희소 부호화


- 재구축 오차와 부호기에 대한 일반화 오차가 줄거나 없어짐
  - 자료의 부호화와 복호기의 훈련을 번갈아 수행



- 종종 질 나쁜 표본들을 산출 & 역전파 수행하기 어려움

## 13.5 PCA의 다양체 해석

- 다양체 ( manifold )
  - 하나의 선형 다양체에 맞게 방향을 정렬



## 13.5 PCA의 다양체 해석

$$\mathbf{h} = f(\mathbf{x}) = \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}). \quad \hat{\mathbf{x}} = g(\mathbf{h}) = \mathbf{b} + \mathbf{V}\mathbf{h}.$$

$$\mathbb{E}[\|\mathbf{x} - \hat{\mathbf{x}}\|^2] \quad \mathbf{V} = \mathbf{W}, \boldsymbol{\mu} = \mathbf{b} = \mathbb{E}[\mathbf{x}]$$

$$\mathbf{C} = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top]$$

$$\mathbf{x} \in \mathbb{R}^D \text{이고 } d < D \text{에 대해 } \mathbf{h} \in \mathbb{R}^d \text{일 때 } \min \mathbb{E}[\|\mathbf{x} - \hat{\mathbf{x}}\|^2] = \sum_{i=d+1}^D \lambda_i$$

- 직교  $\mathbf{W}$  하에서  $\mathbf{h}$ 의 성분들의 분산을 최대화

